

# Cuantización

Fernando Martínez  
fernando.martinez@upc.edu


Departament de Matemàtica • Universitat Politècnica de Catalunya

21 de abril de 2020

# Cuantización

## Ejemplo

Imagen de grises 8 bits  $[0,256)$ , codificamos con 2 bits:



Original

Uniforme: 2 bits por píxel



# Cuantización escalar




Figura: Función de cuantización  $Q(x)$ .

$\{b_i\}_{i=0,\dots,M}$  límites de decisión,  $\{y_i\}_{i=1,\dots,M}$  niveles de reconstrucción,

$$Q(x) = y_i \text{ si } b_{i-1} \leq x < b_i$$

# Cuantización escalar: Problema general (I)

**Problema:** Modelizamos nuestras entradas con una variable aleatoria  $X$  con densidad de probabilidad  $f(x)$ .

Deseamos cuantizar una fuente dando los *límites de decisión*

$\{b_i\}_{i=0,\dots,M}$  y los *niveles de reconstrucción*  $\{y_i\}_{i=1,\dots,M}$  que determinan la función de cuantización  $Q(x) = y_i$  si  $b_{i-1} \leq x < b_i$ .

Definimos<sup>1</sup>:

$$\sigma^2 \equiv \int_{-\infty}^{\infty} [x - Q(x)]^2 f(x) dx = \sum_{i=1}^M \int_{b_{i-1}}^{b_i} [x - Q(x)]^2 f(x) dx \quad (1)$$

$\mathcal{C}$  código con  $M$  palabra de longitudes  $\{l_1, \dots, l_M\}$ . Si  $\tilde{l} = \sum_{i=1}^M l_i p(y_i)$ ,  $p(y_i) = \int_{b_{i-1}}^{b_i} f(x) dx$ , entonces

$$\tilde{l} = \sum_{i=1}^M \int_{b_{i-1}}^{b_i} l_i f(x) dx \quad (2)$$

---

<sup>1</sup> Hay otras *distancias o errores*,  $\sigma$ , que usan  $|x - Q(x)|$ ,  $\sup |x - Q(x)| \dots$

## Cuantización escalar: Problema general (II)

**Problema A** Dado  $\epsilon > 0$ , una cota al *error*, hallar los límites de decisión  $\{b_i\}$ , los niveles de reconstrucción  $\{y_i\}$  y las longitudes de las palabras del código  $\{l_i\}$  que minimizan (2) y satisfacen  $\sigma < \epsilon$

**Problema B** Dado  $\epsilon > 0$ , una cota a la longitud media, hallar los límites de decisión  $\{b_i\}$ , los niveles de reconstrucción  $\{y_i\}$  y las longitudes de las palabras del código  $\{l_i\}$  que minimizan (1) y satisfacen  $\tilde{l} < \epsilon$ .

## Cuantización escalar uniforme

Todos los intervalos son de la misma longitud, salvo tal vez los extremos:

$$x \in [-X_{\max}, X_{\max}], \quad b_i - b_{i-1} = \Delta, \quad \Delta = \frac{2 X_{\max}}{M}$$

Distribución uniforme  $f(x) = \frac{1}{2 X_{\max}}$

Minimizar  $\sigma$ :  $y_i = \frac{b_i + b_{i-1}}{2}$ ,  $y_i - y_{i-1} = \Delta$  niveles de reconstrucción equiespaciados.

Al ser una distribución uniforme podemos utilizar un código de bloque de palabras de longitud  $n$  si  $M = 2^n$ :

$$\sigma^2 = \sum_{i=1}^M \int_{(i-1)\Delta}^{i\Delta} \left[ x - \frac{2i-1}{2} \Delta \right]^2 \frac{1}{2 X_{\max}} dx = \frac{\Delta^2}{12} = \frac{1}{3} \frac{X_{\max}^2}{M^2}.$$

Duplicar el número de intervalos disminuye el error a la mitad. En códigos de bloques, aumentar en 1 bit el tamaño de las palabras reduce el error a la mitad.

## Cuantización escalar uniforme adaptativa

Aunque  $\Delta = b_i - b_{i-1}$  es constante, puede variar con el *tiempo* dependiendo de los valores que va tomando la variable aleatoria.

**FAQ** Forward Adaptative Quantization: Se leen bloques de  $N$  datos y se realiza la cuantización en base a ellos.

**BAQ** Backward Adaptative Quantization: Se actualiza  $\Delta$  a medida que se van leyendo los datos.

### Ejemplo

**FAQ:** De una imagen se leen bloques de  $8 \times 8$  píxeles, se calcula su máximo y su mínimo y se cuantiza en dicho rango [mín, máx] (se han de guardar dichos valores al codificar).

### Ejemplo

**BAQ. Jayant Quantizer:** se varía  $\Delta$  según si los datos van cayendo en los niveles *internos* o *externos*; si es en los *internos* se disminuye  $\Delta$ , si es en los *externos* se aumenta  $\Delta$ .

# Cuantización escalar no uniforme (I)

Volvamos al caso general consideremos los problemas:

(A) Fijamos  $\{b_i\}$ , minimizar  $\sigma^2$  respecto  $\{y_i\}$ . Se ha de cumplir:

$$y_i = \frac{\int_{b_{i-1}}^{b_i} x f(x) dx}{\int_{b_{i-1}}^{b_i} f(x) dx}$$

$y_i$  *centro de masas* del intervalo.

(B) Fijamos  $\{y_i\}$ , minimizar  $\sigma^2$  respecto  $\{b_i\}$ . Se ha de cumplir:

$$b_i = \frac{y_i + y_{i+1}}{2}$$

Los límites de decisión son el punto medio de los niveles de reconstrucción.



# Cuantización escalar no uniforme (I)

**El problema general** es hallar  $\{b_i\}$  e  $\{y_i\}$ .

- ① Fijemos los valores iniciales de  $\{y_i\}$ . Por **(B)** podemos calcular la primera aproximación de los valores  $\{b_i\}$ . Ahora usamos **(A)** para actualizar los valores  $\{y_i\}$  y así sucesivamente.
- ② Supongamos que deseamos hallar  $b_0 = 0, b_1, b_2, \dots, y_1, y_2, \dots$ . Demos un valor tentativo a  $y_1^2$ , resolvemos numéricamente **(A)**

$$y_1 = \frac{\int_{b_0}^{b_1} x f(x) dx}{\int_{b_0}^{b_1} f(x) dx}$$
 siendo  $y_1$  la incógnita. Usando **(B)** obtenemos  $b_1$ , ahora podemos calcular  $y_2$  resolviendo numéricamente **(A)**...

---

<sup>2</sup>El resultado dependerá del valor tomado

# Cuantización vectorial (I)

Tener un diccionario compuesto por vectores  $\{\vec{y}_i\}$  y codificar nuestros vectores según indica el diccionario.

## Ejemplo

Códigos correctores de errores:

(0 0 0 0 0 0 0) 0000

(0 0 0 0 0 1 0)  $\rightarrow$  (0 0 0 0 0 0 0) 0000

(1 0 0 0 0 1 0)  $\rightarrow$  (0 0 0 0 0 0 0) 0000

(0 0 0 0 0 1 1)  $\rightarrow$  (1 0 0 0 0 1 1) 1001

(0 0 0 0 1 0 1)  $\rightarrow$  (0 1 0 0 1 0 1) 0101

(0 0 0 0 1 1 0)  $\rightarrow$  (0 0 1 0 1 1 0) 0010

(0 0 0 1 0 1 1)  $\rightarrow$  (0 0 0 1 1 1 1) 0001

(0 0 0 1 1 0 0)  $\rightarrow$  (1 0 0 1 1 0 0) 1000

(0 1 0 0 1 0 1) 0101

(1 0 1 1 0 1 0) 1010

## Cuantización vectorial (II)

### K-means – Linde-Buzo-Gray (LGB)

- 1.) Inicializamos un conjunto de vectores de reconstrucción  $\{\vec{y}_i^{(1)}\}$ ,  $k = 1$ ,  $D^{(0)} = 0$ ,  $\epsilon$  lindar.
- 2.) Hallamos las regiones de cuantización

$$V_i^{(k)} = \left\{ \vec{x}, d(\vec{x}, \vec{y}_i^{(k)}) < d(\vec{x}, \vec{y}_j^{(k)}) \forall j \neq i \right\}$$

- 3.) Calculamos la distorsión

$$D^{(k)} = \sum_{i=1}^M \int_{V_i^{(k)}} \|\vec{x} - \vec{y}_i^{(k)}\| f(\vec{x}) d\vec{x}$$

- 4.) Si  $\frac{D^{(k)} - D^{(k-1)}}{D^{(k)}} < \epsilon$  entonces **stop**.
- 5.)  $K = k + 1$ , calculamos los nuevos valores de  $\{\vec{y}_i^{(k)}\}$ , que son los centroides de  $\{V_i^{(k)}\}$  y volvemos a 2.

## Cuantización vectorial (III)

### Observaciones:

- I) Cuando se usa para clasificar objetos se utiliza un conjunto para entrenar y otro de test.
- II) No siempre converge a la solución óptima
- III) Depende de la elección inicial de  $\{\vec{y}_i^{(1)}\}$ .  
Una forma de elegirlos es empezar con un vector que sea el centroide. A continuación se perturba para obtener dos vectores, se aplica el algoritmo, los nuevos centroides se vuelven a "dividir" así hasta obtener el número de vectores deseado.
- IV) Depende de las definiciones de  $d(\vec{x}, \vec{y})$  y  $\|\vec{x}\|$  y de cómo se actualiza.

# Cuantización de métodos predictivos (I)

## Ejemplo

Original	0	1,2	2,4	4,9	7,1	6,3	4,8	3,4	0,9	-0,9	-2,4	-4,1
Diferencias		1,2	1,2	2,5	2,2	-0,8	-1,5	-1,4	-2,5	-1,8	-1,5	-1,7
Cuantizado		1,5	1,5	2,5	2,5	-0,5	-1,5	-1,5	-2,5	-1,5	-1,5	-1,5
Recuperado		1,5	3	5,5	8	7,5	6	4,5	2	0,5	-1	-2,5
Error		0,3	0,6	0,6	0,9	1,2	1,2	1,1	1,1	1,4	1,4	1,6

Límites: ...-3,-2,-1,0,1,2,3...

Niveles -3,5, -2,5, -1,5, -0,5, 0,5, 1,5, 2,5, 3,5...

El error va creciendo poco a poco.

## Cuantización de métodos predictivos (II)

$\{x_n\}$  la secuencia original

$\{d_n\}$  la secuencia de diferencias,  $d_n = x_n - x_{n-1}$

$\{\hat{d}_n\}$  la secuencia de diferencias cuantizadas,  $\hat{d}_n = Q(d_n) = d_n + e_n$

$\{\hat{x}_n\}$  la secuencia reconstruida

Calculemos  $\hat{x}_n = \hat{x}_{n-1} + \hat{d}_n$ , tomando  $\hat{x}_0 = x_0$ :

$$\hat{x}_1 = \hat{x}_0 + \hat{d}_1 = x_0 + d_1 + e_1 = x_0 + (x_1 - x_0) + e_1 = x_1 + e_1$$

$$\begin{aligned}\hat{x}_2 &= \hat{x}_1 + \hat{d}_2 = (x_1 + e_1) + (d_2 + e_2) = \\ &= x_1 + (x_2 - x_1) + e_1 + e_2 = x_2 + e_1 + e_2\end{aligned}$$

...

$$\hat{x}_k = x_k + \sum_{i=1}^k e_i$$

Como la media del  $e_i$  será 0, se puede pensar que el error se cancelará a medida que recuperamos más elementos de la secuencia pero en la práctica no acostumbra a ser así (paseo aleatorio o del borracho).

## Cuantización de métodos predictivos (III)

Para evitar este problema la secuencia de diferencias se construye

$$d_n = x_n - \hat{x}_{n-1}$$

### Ejemplo

Original	0	1,2	2,4	4,9	7,1	6,3	4,8	3,4	0,9	-0,9	-2,4	-4,1
Diferencias		1,2	0,9	2,9	2,6	-0,7	-1,7	-1,6	-2,6	-1,9	-1,9	-2,1
Cuantizado		1,5	0,5	2,5	2,5	-0,5	-1,5	-1,5	-2,5	-1,5	-1,5	-2,5
Recuperado		1,5	2	4,5	7	6,5	5	3,5	1	-0,5	-2	-4,5
Error		0,3	-0,4	-0,4	-0,1	0,2	0,2	0,1	0,1	0,4	0,4	-0,4

Límites: ...-3,-2,-1,0,1,2,3...

Niveles -3,5, -2,5, -1,5, -0,5, 0,5, 1,5, 2,5, 3,5...

El error es el error producido en la cuantización.

# Cuantización de métodos predictivos (IV)

$\{x_n\}$  la secuencia original

$\{d_n\}$  la secuencia de diferencias,  $d_n = x_n - \hat{x}_{n-1}$

$\{\hat{d}_n\}$  la secuencia de diferencias cuantizadas,  $\hat{d}_n = Q(d_n) = d_n + e_n$

$\{\hat{x}_n\}$  la secuencia reconstruida

$$\hat{x}_0 = x_0$$

$$\hat{x}_1 = \hat{x}_0 + \hat{d}_1 = \hat{x}_0 + d_1 + e_1 = \hat{x}_0 + (x_1 - \hat{x}_0) + e_1 = x_1 + e_1$$

$$\hat{x}_2 = \hat{x}_1 + \hat{d}_2 = \hat{x}_1 + (d_2 + e_2) = \hat{x}_1 + (x_2 - \hat{x}_1) + e_2 = x_2 + e_2$$

...

$$\hat{x}_k = x_k + e_k$$



## Cuantización de métodos predictivos (V)

En este proceso estamos asumiendo que el siguiente valor es igual al anterior y codificamos la diferencia:

$$p_n = f(\hat{x}_{n-1}) = \hat{x}_{n-1}, \quad d_n = x_n - p_n, \quad \hat{d}_n = Q(d_n) \quad \hat{x}_n = p_n + \hat{d}_n$$

En general podemos suponer:

$$p_n = f(\hat{x}_{n-1}, \hat{x}_{n-2}, \dots, \hat{x}_{n-N})$$

$f$  depende de  $\hat{x}_i$  (no de  $x_i$ ) porque el decodificador sólo tiene acceso a  $\hat{x}_i$

### Ejemplo

El valor de un píxel  $\Theta$  se puede predecir a partir de los valores A, B,

C,... ya leídos,

B	C	D
A	$\Theta$	

- filtro lineal (media ponderada de los píxeles),
- filtro no lineal (mediana, moda, máximo, mínimo...)